
SUPER CODING

Mini-ImageNet+

: 이미지 분류 및 이미지 캡셔닝 프로젝트


슈퍼코딩 3팀 김민주, 선종일, 안가인	blesty00@gmail.com tjswhddlf114@gmail.com sbin4142@gmail.com
--------------------------	--

목차

- 01 프로젝트 개요
- 02 데이터셋 구축
- 03 이미지 분류 설계 및 실험 결과
- 04 이미지 캡셔닝 설계 및 실험 결과
- 05 결과 분석 및 평가
- 06 MLOps 및 배포
- 07 결론 및 회고


1. 프로젝트 개요

프로젝트 목표 및 범위



이미지 분류 모델 구축

- 입력 이미지를 50개 클래스 중 하나로 분류




이미지 캡셔닝 모델 구축

- 이미지의 객체와 장면 정보를 자연어 문장으로 생성



모델 성능 최적화

데이터셋 구축 → 모델 비교 → 성능 개선 → 최종 모델 선정까지 전 과정 수행



MLOps & 배포

- 실험 재현 가능한 엔드-투-엔드 MLOps 파이프라인 구축

2. 데이터셋 구축

2-1. 초기 데이터셋 구성

- 클래스: 음식, 동물, 꽃, 과일, 탈것, 패션 및 잡화 등 다양한 시각 범주로 구성

항목	내용
초기 데이터셋 버전	raw-20260509-v1
클래스 수	50개
클래스당 이미지 수	약 220장
총 이미지 수	약 11,000장
Split	train 70% / validation 15% / test 15%

2-2. 데이터셋 최종 구성 - 분류 모델

- 깨진 이미지, 중복 이미지, label ambiguity 이미지 제거 및 부족 클래스 보완

항목	내용
정제 데이터셋 버전	cls_raw-20260525-v2
추가 수집 출처	Hugging Face, Kaggle, COCO dataset
클래스당 이미지 수	약 180~220장
총 이미지 수	약 10,370장


2-3. 데이터셋 최종 구성 - 캡셔닝 모델

- 단일 객체 중심 → 복합 장면 이미지로 변경

항목	내용
데이터셋	COCO Caption Dataset
이미지 수	Train 7,744 / Val 1,660 / Test 1,660
캡션 수	이미지당 5개
활용 목적	장면 설명 학습

3. 이미지 분류 설계 및 실험 결과

3-1. 전체 실험 흐름




3-2. 사용 모델 구조

구분	모델	역할
CNN	ResNet18	baseline 모델
CNN	EfficientNet-B0	CNN 계열 주요 비교 모델
CNN	ConvNeXt-T	CNN 계열 비교 후보
CNN	MobileNetV3	경량 CNN 비교 후보
Transformer	ViT-S/16	Vision Transformer 비교 후보
Transformer	Swin-T	최종 Best Backbone
Transformer	DeiT-S	Transformer 비교 후보

3-3. 기본 학습 조건


항목	설정	항목	설정
Epoch	50	Augmentation	None
Batch Size	32	Pretrained	True
Optimizer	Adam	Input Size	224*224
Learning Rate	CNN: 0.001 / Transformer: 0.0005	Seed	42
Scheduler	None	Dataset	raw-20260509-v1
Loss	CrossEntropyLoss		

3-4. 모델 선정 기준



Validation Macro F1-score

- 1차 선정 기준
- 해당 점수가 높은 모델 선정




Validation Loss 안정성

- Step2: Backbone 비교 시 추가 참고



학습 시간

- Step2: Backbone 비교 시 추가 참고



Overfitting 여부

- Step2: Backbone 비교 시 추가 참고
- Train/Validation 성능 차이 확인

3-5. Backbone 비교 결과

• 최종 Backbone: Swin-T

항목	EfficientNet-B0	Swin-T
계열	CNN	Transformer
평균 Validation Macro F1	약 0.7892	약 0.8850
Validation Loss	약 0.81	약 0.49
평균 학습 시간	약 30분 34초	약 27분 40초
Overfitting	존재	상대적으로 적음

3-6. 데이터셋 정제 후 재검증 결과

- Best Backbone으로 선정된 Swin-T를 고정 → 정제된 데이터셋으로 재실험
- 최종 데이터셋: cls_raw-20260525-v2

항목	정제 전	정제
Dataset	raw-20260509-v1	cls_raw-20260525-v2
Validation Macro F1	0.88008 (3-seed 평균)	0.92209
Validation Loss	0.49009 (3-seed 평균)	0.29486
Validation Accuracy	0.88060 (3-seed 평균)	0.91971

3-7. Augmentation 실험

- 모델 Swin-T, 데이터셋 cls_raw-20260525-v2 으로 고정
- 최종 Augmentation: None

실험	Best Validation Macro F1	결론
None	0.92209	가장 높음
MixUp	0.92200	거의 동일하나 개선 없음
CutMix	0.92148	소폭 감소

3-8. Hyperparameter Tuning


- 모델 Swin-T, 데이터셋 cls_raw-20260525-v2, Augmentation: None 으로 고정
- 최종 Optimizer: AdamW

항목	비교값	최종 선택
Learning Rate	0.0005, 0.0001	0.0005
Batch Size	32, 16	32
Optimizer	Adam, AdamW	AdamW
Scheduler	None, CosineAnnealingLR	None
Weight Decay	0.01, 0.05	0.05
Label Smoothing	0.0, 0.05, 0.1	0.0 (사용 안 함)

최종 모델 선정


항목	최종 설정	항목	최종 설정
Backbone	Swin-T	Optimizer	AdamW
Dataset	cls_raw-20260525-v2	Scheduler	None
Augmentation	None	Weight Decay	0.05
Learning Rate	0.0005	Label Smoothing	0.0
Batch Size	32		

3-9. 최종 모델 성공 기준



Metrics

- Test Accuracy ≥ 0.85
- Test Macro F1 ≥ 0.85




Confusion Matrix

- 대각선 집중



Latent Space UMAP

- 클래스별 Cluster 형성




Grad-CAM


- 시각화 정상 생성

4. 이미지 캡셔닝 설계 및 실험 결과

4-1. 전체 실험 흐름



4-1. 전체 실험 흐름



4-2. 사용 모델 구조

- Decoder 비교 모델
- RNN 계열과 Transformer 계열을 비교

구분	모델	역할
RNN	LSTM	RNN 계열의 순차적 문장 생성 구조
RNN	GRU	LSTM보다 경량화된 RNN 구조
Transformer	Transformer	Self-Attention 기반 문장 생성 구조

4-2. 사용 모델 구조

- Encoder 비교 모델
- CNN 계열과 Transformer 계열에서 선정하여 backbone 성능을 비교


구분	모델	역할
CNN	ResNet18	CNN 계열의 baseline 모델
Transformer	ViT-S/16	Self-Attention 기반 Vision Encoder
Transformer	Swin-T	Window Attention 기반 Vision Encoder

4-3. 기본 학습 조건

항목	설정	항목	설정
Epoch	20	Max Caption Length	30
Batch Size	32	Encoder	Pretrained
Optimizer	Adam	Encoder Input Size	224*224
Learning Rate	0.0001	Seed	42
Scheduler	None	Dataset	raw-20260509-v1
Loss	CrossEntropyLoss		

4-4. 모델 선정 기준

정성 평가



지표 및 기준


생성 문장의 자연스러움, 객체 설명 정확도, 반복 생성 및 hallucination 여부



목적


캡션 문장의 문법적 완성도와 시각 정보 일치성을 심층적으로 평가

정량 평가



지표 및 기준

CIDEr, BLEU, Validation Loss



목적

객관적인 수치 비교를 통해 모델의 기본적인 생성 성능 및 수렴도를 검증

4-5. Decoder Baseline 비교 결과



정성 지표

LSTM

in this image we can see an airplane flying in the sky

GRU

in this image we can see an airplane flying in the sky

Transformer

in this image we can see an airplane flying in the sky

4-5. Decoder Baseline 비교 결과

- 정량 지표
- Transformer 가 전체 데이터셋 기준 정량 평가에서 가장 우수한 성능

Decoder	Validation Loss	BLEU-4	CIDEr
LSTM	0.99302	0.37909	0.74282
GRU	0.96236	0.38102	0.67165
Transformer	0.84491	0.40138	0.79299

4-6. 데이터셋 변경 결과

- raw-20260509-v1 : 기존 객체 중심 이미지 데이터만으로는 자연스러운 장면 설명을 학습하기 어려움
- cap_raw-20260524-v1 : 단일 객체보다 복합 장면을 많이 포함하하는 데이터셋으로 변경

항목	raw-20260509-v1	cap_raw-20260524-v1
데이터 특성	객체 분류 중심	장면 설명 중심
이미지당 캡션 수	2	5
학습 시 사용 캡션 수	1	2
학습 목표	객체 인식	객체, 상태, 관계, 배경 설명

4-6. 데이터셋 변경 결과

기존 데이터셋 : raw-20260509-v1

- in this image we can see an airplane flying in the sky,
- in this image we can see a food item on the plate which is placed on the table,
- in this image we can see a flower in the background there are plants

변경 데이터셋 : cap_raw-20260524-v1

- a desk with a computer and a keyboard and mouse .
- a person with a teddy bear sitting on a bed .
- a cat is sitting in the middle of a chair .

4-6. 데이터셋 변경 결과

- 정량 지표
- 정량 평가 지표는 감소하였으나 생성 문장의 다양성과 장면 설명 능력은 향상

데이터셋	Validation Loss	BLEU-4	CIDEr
raw-20260509-v1	0.84491	0.40138	0.79299
cap_raw-20260524-v1	2.59930	0.14241	0.43862

4-7. Encoder 비교 결과



정성 지표

ResNet18

a blue and blue boat filled with lots of boats .

Swin-T

A group of boats with colorful flags at docked

ViT

a group of boats with <unk> on a body of water

- Swin-T 에서 가장 우수한 성능

4-7. Encoder 비교 결과

- 정량 지표
- Swin-T가 정량 평가와 정성 평가 모두에서 가장 우수한 성능

Encoder	Validation Loss	BLEU-4	CIDEr
ResNet18	2.59930	0.14241	0.43862
Swin-T	2.44602	0.17090	0.55499
ViT	2.50297	0.16090	0.52026

4-8. Tokenizer 비교 결과



정성 지표

Subword 1000

a couple of men standing next to each other.

Subword 1500

a couple of people are sitting on a bench.

Subword 2000

a couple of people with a beardy seat in a room.

- Subword 에서 Hallucination 현상과 의미적으로 부자연스러운 문장이 생성

4-8. Tokenizer 비교 결과

- 정량 지표
- Subword-level에서 BLEU 및 CIDEr 성능이 전반적으로 향상

Tokenizer	Validation Loss	BLEU-4	CIDEr
Word-level	2.44602	0.17090	0.55499
Subword vocab 1000	2.28855	0.19310	0.63337
Subword vocab 1500	2.39733	0.19366	0.63158
Subword vocab 2000	2.44271	0.19884	0.63536

4-9. Transformer Decoder 구조 실험



정성 평가

Attention Head 개수 최적화

nhead 4

a pizza with a knife and a fork on a plate .

nhead 8

a plate of pizza with cheese and vegetables on a table .

- nhead 4 에서 Hallucination 발생

4-9. Transformer Decoder 구조 실험

- 정량 지표
- 유사한 성능을 기록

Attention Head	Validation Loss	BLEU-4	CIDEr
nHead 4	2.44456	0.18010	0.56305
nHead 8	2.44293	0.17690	0.56046

4-9. Transformer Decoder 구조 실험



정성 평가

Positional Encoding 방식 검증

sinusoidal

a woman is petting a giraffe in a zoo .

learnable

a woman is sitting on a dirt road with a giraffe behind her .

- Learnable 에서 Hallucination 발생

4-9. Transformer Decoder 구조 실험

- 정량 지표
- Learnable 에서 BLEU 및 CIDEr 성능 향상, Validation Loss 증가

Positional Encoding	Validation Loss	BLEU-4	CIDEr
sinusoidal	2.44293	0.17690	0.56046
learnable	2.47940	0.18118	0.56984

4-10. 정규화 및 일반화 성능 개선 결과



정성 평가

Dropout

0.1

a person on a snowboard on a snowy slope .

0.2

a person on a snow board on a snowy hill .

0.3

a person on a snowboard on a snowy slope .

- 생성 캡션 품질은 세 설정 간 큰 차이 없음

4-10. 정규화 및 일반화 성능 개선 결과

- 정량 지표
- Dropout 0.3 에서 가장 높은 BLEU 및 CIDEr 성능 기록, 최종 설정으로 선정

Dropout	Validation Loss	BLEU-4	CIDEr
0.1	2.44293	0.17690	0.56046
0.2	2.41895	0.17729	0.56765
0.3	2.42717	0.18564	0.57074

4-10. 정규화 및 일반화 성능 개선 결과



정성 평가

Weight Decay

0.0001

a giraffe standing next to a woman in a zoo .

0.0005

a woman standing next to a giraffe eating a hot dog .

0.001

a giraffe standing next to a woman in a zoo .

- 0.0005에서는 Hallucination과 반복 생성 현상이 확인

4-10. 정규화 및 일반화 성능 개선 결과

- 정량 지표
- 정량적 성능은 전반적으로 유사

Weight Decay	Validation Loss	BLEU-4	CIDEr
0.0001	2.42717	0.18564	0.57074
0.0005	2.42821	0.18521	0.57357
0.001	2.42643	0.18429	0.57031

4-10. 정규화 및 일반화 성능 개선 결과



정성 평가

Label Smoothing

0

a pizza on a plate on a table .

0.05

a pizza with cheese and cheese on a plate .

0.1

a plate of pizza with cheese and cheese .

- 0.05와 0.1에서는 객체를 잘못 인식하고 반복 생성

4-10. 정규화 및 일반화 성능 개선 결과

- 정량 지표
- 0.05에서 가장 높은 성능을 기록, Label Smoothing 값이 증가할수록 Loss 가 지속적으로 증가
- 0을 최종 설정으로 선정

Label Smoothing	Validation Loss	BLEU-4	CIDEr
0	2.42643	0.18429	0.57031
0.05	2.90918	0.18723	0.57567
0.1	3.33286	0.18638	0.57487

4-11. 최적화 실험 결과



정성 평가

Learning Rate Tuning

0.0001

a giraffe standing next to a woman in a zoo .

0.0003

a woman standing next to a giraffe in a zoo .

0.00005

a woman standing next to a giraffe eating a fence .

- 0.0003과 0.00005 에서 Hallucination 현상 확인

4-11. 최적화 실험 결과

- 정량 지표
- 0.0001이 Validation Loss, BLEU-4, CIDEr 모두 가장 우수한 성능

Learning Rate	Validation Loss	BLEU-4	CIDEr
0.0001	2.42643	0.18429	0.57031
0.0003	2.51517	0.17115	0.54980
0.00005	2.51623	0.17589	0.53540

4-11. 최적화 실험 결과



정성 평가

Learning Rate Scheduler

None

a giraffe standing next to a woman in a zoo .

Scheduler

a woman standing next to a giraffe eating a fence .

- None 에서 이미지의 주요 객체와 상황을 보다 자연스럽게 안정적으로 설명

4-11. 최적화 실험 결과

- 정량 지표
- Noam Scheduler 적용했을 때 Validation Loss, BLEU-4, CIDEr 모두 감소

Scheduler	Validation Loss	BLEU-4	CIDEr
None	2.42643	0.18429	0.57031
Noam Scheduler	2.51623	0.17589	0.53540

4-11. 최적화 실험 결과



정성 평가

Batch Size

16

a woman is petting a giraffe and a woman .

32

a giraffe standing next to a woman in a zoo .

64

a woman standing next to a giraffe and a woman .

- Batch Size 32 최종 선정

4-11. 최적화 실험 결과

- 정량 지표
- Batch Size 32에서 가장 우수한 Validation Loss, BLEU-4, CIDEr 성능

Batch Size	Validation Loss	BLEU-4	CIDEr
16	2.4285	0.17945	0.56824
32	2.42643	0.18429	0.57031
64	2.45775	0.17186	0.53895

4-12. Decoding Algorithm 비교 결과



정성 평가

greedy

a pizza on a plate on a table .

beam3

a slice of pizza on a plate on a table .

beam5

a slice of pizza on a plate on a table .

- Beam Size 3 최종 선정

4-12. Decoding Algorithm 비교 결과

- 정량 지표
- Beam Search 적용 시 BLEU 및 CIDEr 성능이 크게 향상


Decoding Algorithm	Validation Loss	BLEU-4	CIDEr
Greedy	2.42643	0.18429	0.57031
Beam Search 3	2.42643	0.19973	0.60544
Beam Search 5	2.42643	0.20061	0.60638

4-13. 최종 이미지 캡셔닝 모델

항목	설정	항목	설정
Dataset	cap_raw-20260524-v1	Dropout	0.3
Encoder	Swin-T	Weight Decay	0.001
Decoder	Transformer Decoder	Label Smoothing	0
Tokenizer	Word-level	Optimizer	AdamW
n_layers	6	Learning Rate	0.0001
d_model	512	Scheduler	None
nhead	8	Batch Size	32
Activation	ReLU	Decoding	Beam Search 3
Positional Encoding	Sinusoidal	Checkpoint	./outputs/captioning/swin-transformer_final_best.pt

4-13. 최종 모델 성공 기준

정성 평가




객체 및 장면 인식

- 이미지의 주요 객체를 정확하게 설명
- 단순 객체 나열이 아닌 장면 중심의 문장을 생성




문장의 자연스러움

- 반복 생성(Repetition)이 발생하지 않을 것
- 이미지에 존재하지 않는 객체 또는 상황을 생성하는 Hallucination이 최소화될 것



BLEU

- $\text{BLEU-1} \geq 0.40$
- $\text{BLEU-2} \geq 0.25$
- $\text{BLEU-3} \geq 0.15$
- $\text{BLEU-4} \geq 0.10$



CIDEr

- $\text{CIDEr} \geq 0.30$

정량 평가

5. 결과 분석 및 평가

5-1. 최종 이미지 분류 모델 성능

- ✓ Accuracy, Macro F1 → 목표 성능(0.85 이상) 충족
- ✓ Accuracy와 Macro F1이 유사하여 클래스 간 균형 잡힌 성능 확인


Metric	Score
Accuracy	0.8964
Precision	0.9001
Recall	0.8961
Macro F1	0.8961

5-2. 데이터셋 정제 전후 변화

- ✓ 모델 구조 변경 없이 성능 향상
- ✓ 데이터셋 정제는 최종 성능 향상의 핵심 요인

항목	정제 전	정제 후
Validation Loss	0.49009	0.29486 ↓ (-39.8%)
Validation Accuracy	0.88060	0.9197 ↑
Validation Macro F1	0.88008	0.9221 ↑ (+4.2%)

5-3. Confusion Matrix 분석



성능 우수 클래스

- banana, bicycle, bulldog, elephant, motorcycle, sunflower

성능 낮은 클래스

- earrings, bracelet, necklace, sandwich, salad, dumpling

핵심 결과

고

- 대부분의 샘플이 대각선에 집중
- 전체적으로 높은 분류 성능 확인

5-3. Confusion Matrix 분석

✔ 낮은 성능 / 오분류 원인 분석

구분	클래스	해석
액세서리	earrings, bracelet, necklace	객체가 작고 배경 영향이 큼
음식	sandwich, salad, dumpling	음식류는 형태 변화가 크고 클래스 간 유사성이 높음


5-4. 저해상도 이미지 영향 분석

- 256px 미만 이미지 비율 상위 클래스

클래스	비율
aster, lavender	54%
squirrel	47%
marigold, iris	45%

- ✓ 분석 결과, 저해상도 이미지 비율 <-> 성능 간 뚜렷한 상관관계 없음
- ✓ 해상도보다 클래스 간 시각적 유사성이 분류 성능에 더 큰 영향

5-5. Latent Space UMAP 분석



주요 클래스는 뚜렷한 클러스터 형성

- airplane, bicycle, elephant, motorcycle, sunflower

꽃·음식류 클래스는 클러스터가 중첩


- 시각적 유사성이 높은 클래스 간 혼동 발생

핵심 결과

고

- Feature Space에서도 클래스 간 유사성이 반영됨

5-6. Grad-CAM 분석



정분류 사례: banana



오분류 사례: aster

정분류

- 객체 중심 영역에 집중

오분류

- 배경 및 주변 정보에 집중

핵심 결과

고

- 작은 객체와 복잡한 배경에서 오분류 증가
- 모델의 Attention 위치가 예측 성능에 직접적인 영향


5-7. 학습 곡선 해석 및 성능 한계

핵심 결과

ㅎ

- 액세서리류: 작은 객체, 배경 영향
- 음식류: 높은 시각적 유사성
- MixUp, CutMix 효과 제한적

✓ 데이터 특성이 성능 한계의 주요 원인



5-8. 최종 이미지 캡셔닝 모델 성능



정성 평가

a man riding a horse on a dirt road .


- 이미지의 주요 객체와 상황을 정확하게 설명
- Hallucination 없음
- 객체 반복 생성 없음
- 자연스러운 문장 생성

5-8. 최종 이미지 캡셔닝 모델 성능

- 정량 평가
- Bleu : 보통
- CIDEr : 괜찮음

Metric	Score	보통	괜찮음
Bleu_1	0.58290	0.40	0.60
Bleu_2	0.41275	0.25	0.45
Bleu_3	0.28504	0.15	0.30
Bleu_4	0.19973	0.10	0.20
CIDEr	0.60544	0.30	0.60

5-8. 최종 이미지 캡셔닝 모델 성능



Attention Heatmap 시각화

- 각 단어가 의미하는 객체 또는 영역에 Attention이 집중

6. MLOps 및 배포

6. MLOps 및 배포

도구	사용 목적
GitHub	코드 버전 관리 및 협업
Docker	팀원 간 동일한 실행 환경 구성
DVC	데이터셋과 모델 checkpoint 버전 관리
W&B	실험 설정, metric, 그래프 기록
Gradio	모델 결과를 웹 데모 형태로 제공
Hugging Face Spaces	Gradio 데모 배포

7. 결론 및 회고

7-1. 데이터 품질의 중요성

“데이터의 품질이 성능에 가장 큰 영향”

- ✓ 데이터 정제는 성능 향상의 핵심 요인이다
- ✓ 태스크에 맞는 데이터셋이 필요하다
- ✓ 데이터 품질은 평가 해석에도 영향을 준다

7-2. 정성 평가의 필요성

“점수는 비교 기준, 품질은 직접 검수”

- ✓ 정량 평가는 모델 간 객관적 비교 기준을 제공한다
- ✓ 정성 평가는 실제 생성 품질을 판단하는 데 필요하다
- ✓ 전체 흐름을 정리하며 다음 논의나 행동으로 자연스럽게 연결합니다.

7-3. 향후 개선 방향

개선 방향	세부 사항
데이터셋 개선	낮은 성능 클래스 보강
	캡셔닝 데이터셋 확대
모델 성능 개선	오분류 샘플 분석 강화
	캡셔닝 평가 지표 확장
서비스 고도화	Gradio 통합 서비스 개선
	모델 경량화 검토

7-4. 최종 회고

본 프로젝트를 통해 이미지 분류와 이미지 캡셔닝 문제를 모두 경험하며 데이터 품질, 모델 구조, 평가 방법의 중요성을 확인하였다. 특히 이미지 분류에서는 데이터셋 정제만으로도 성능이 크게 향상되었으며, 데이터 품질이 모델 성능의 기반이라는 점을 확인할 수 있었다.

또한 이미지 캡셔닝에서는 정량 지표가 높다고 해서 항상 좋은 문장이 생성되는 것은 아니라는 점을 확인하였다. BLEU, CIDEr와 같은 정량 평가뿐 아니라 실제 생성 문장에 대한 정성 평가가 함께 이루어져야 하며, 최종적으로는 프로젝트 목적에 적합한 모델을 선택하는 과정이 중요하다는 점을 배울 수 있었다.

감사합니다