

이미지 분류 및 이미지 캡셔닝 모델 성능 분석 최종 보고서

목차

1. 프로젝트 개요
2. 데이터셋 구축
3. 이미지 분류 설계 및 실험 결과
4. 이미지 캡셔닝 설계 및 실험 결과
5. 결과 분석 및 평가
6. MLOps 및 배포
7. 결론 및 회고

1. 프로젝트 개요

1-1. 프로젝트 목표

본 프로젝트는 이미지 데이터를 활용하여 이미지 분류 모델과 이미지 캡셔닝 모델을 구축하는 것을 목표로 했다. 이미지 분류 모델은 입력 이미지가 어떤 클래스에 속하는지 예측하는 역할을 맡았다. 이미지 캡셔닝 모델은 입력 이미지를 바탕으로 이미지의 주요 객체와 장면 정보를 자연어 문장으로 생성하는 역할을 맡았다.

본 프로젝트는 단순히 모델을 구현하는 것을 넘어, 데이터셋 구축 → 모델 비교 → 성능 개선 → 최종 모델 선정 과정을 통해 각 과제에 적합한 구조를 검증하는 것을 목표로 하였다.

1-2. 프로젝트 범위 및 기대 효과

본 프로젝트의 주요 수행 범위는 다음과 같다.

구분	이미지 분류	이미지 캡셔닝
수행 내용	50개 클래스 이미지 데이터셋 구축, Backbone 비교, 데이터셋 정제, augmentation 실험, hyperparameter tuning, 최종 test 평가	COCO 기반 캡셔닝 데이터셋 적용, Encoder 비교, Tokenizer 비교, Transformer Decoder 구조 실험, 정규화 및 학습 전략 실험, Beam Search 적용
성능 평가	Validation Loss, Accuracy, Precision, Recall, Macro F1	Validation Loss, BLEU, CIDEr, 생성 캡션 정성 평가

구분	이미지 분류	이미지 캡셔닝
분석	Confusion Matrix, UMAP, Grad-CAM	캡션 품질 비교, Attention Heatmap
실험 관리	Git, DVC, W&B 기반 코드·데이터·모델·실험 결과 관리	
배포	Gradio 기반 이미지 분류 및 이미지 캡셔닝 데모 구성, Hugging Face Spaces 배포	

최종적으로 본 프로젝트는 이미지 분류 모델과 이미지 캡셔닝 모델을 각각 구축하고, 두 모델을 하나의 서비스 흐름에서 활용할 수 있는 멀티모달 이미지 분석 시스템의 기반을 마련하는 것을 목표로 하였다.

2. 데이터셋 구축

2-1. 초기 데이터셋 구성

초기 실험 전에는 50개 클래스로 구성된 이미지 데이터셋을 구축하였다. 초기 데이터셋은 `raw-20260509-v1`이며, 클래스당 약 220장의 이미지를 목표로 수집하였다.

항목	내용
초기 데이터셋 버전	<code>raw-20260509-v1</code>
클래스 수	50개
클래스당 이미지 수	약 220장
총 이미지 수	약 11,000장
Split	train 70% / validation 15% / test 15%

클래스는 음식, 동물, 꽃, 과일, 탈것, 패션 및 잡화 등 다양한 시각 범주로 구성하였다. 이를 통해 특정 범주에만 치우치지 않고 다양한 이미지 특징을 학습할 수 있도록 설계하였다.

2-2. 분류 데이터셋 정제 및 재구축

초기 데이터셋을 활용한 실험 과정에서 깨진 이미지, 중복 이미지, label ambiguity가 큰 이미지가 모델 성능에 영향을 줄 수 있음을 확인하였다. 이에 따라 데이터셋을 정제하고 `cls_raw-20260525-v2` 버전을 새로 구성하였다.

정제 항목	목적
깨진 이미지 제거	학습 중 오류 및 잘못된 feature 학습 방지
중복 이미지 제거	특정 이미지에 대한 과적합 완화
label ambiguity 이미지 제거	클래스 간 혼동 감소
부족 클래스 보완	클래스별 데이터 수 균형 개선

정제된 데이터셋은 다음과 같다.

항목	내용
정제 데이터셋 버전	cls_raw-20260525-v2
추가 수집 출처	Hugging Face, Kaggle, COCO dataset
클래스당 이미지 수	약 180~220장
총 이미지 수	약 10,370장

2-3. 캡셔닝 데이터셋 전환

캡셔닝 실험에서는 기존 객체 중심 이미지 데이터만으로는 자연스러운 장면 설명을 학습하기 어렵다고 판단했다. 기존 데이터는 특정 객체를 식별하는 데는 유리했지만, 객체의 상태, 위치, 배경, 객체 간 관계를 설명하는 데는 한계가 있었다.

따라서 캡셔닝 실험에서는 COCO 기반 데이터셋을 적용했다. COCO 데이터셋은 이미지 하나에 여러 참조 캡션이 존재하고, 단일 객체보다 복합 장면을 많이 포함하고 있어 캡셔닝 학습에 적합하다고 판단하였다.

항목	내용
데이터셋	COCO Caption Dataset
이미지 수	Train 7,744 / Val 1,660 / Test 1,660
캡션 수	이미지당 5개
활용 목적	장면 설명 학습

3. 이미지 분류 설계 및 실험 결과

3-1. 전체 실험 흐름

이미지 분류 실험은 다음 순서로 진행되었다. baseline 모델을 먼저 학습하고, 이후 CNN backbone과 Transformer backbone을 비교한 뒤, 최종 backbone을 선정하고 데이터셋 정제, augmentation, hyperparameter tuning, test evaluation으로 이어지는 흐름을 정의했다.

```

Step 1. Baseline 실험: ResNet18
Step 2. Backbone 비교: CNN 계열 vs Transformer 계열
Step 3. 데이터셋 정제 후 Best Backbone 재검증
Step 4. Augmentation 비교: None / MixUp / CutMix
Step 5. Hyperparameter Tuning
Final. Test Dataset Evaluation

```

3-2. 사용 모델 구조

실험에서는 CNN 계열과 Transformer 계열 backbone을 비교했다. CNN backbone으로 ResNet18, EfficientNet-B0, ConvNeXt-T, MobileNetV3가, Transformer backbone으로 ViT-S/16, Swin-Tiny, DeiT-S를 사용했다.

구분	모델	역할
CNN	ResNet18	baseline 모델
CNN	EfficientNet-B0	CNN 계열 주요 비교 모델
CNN	ConvNeXt-T	CNN 계열 비교 후보
CNN	MobileNetV3	경량 CNN 비교 후보
Transformer	ViT-S/16	Vision Transformer 비교 후보
Transformer	Swin-T	최종 Best Backbone
Transformer	DeiT-S	Transformer 비교 후보

3-3. 기본 학습 조건

분류 실험의 기본 학습 조건은 다음과 같다. Learning rate의 경우 CNN 계열은 일반적인 fine-tuning 설정에 따라 0.001로 설정하였으며, Transformer 계열은 학습 안정성과 pretrained 가중치 보존을 위해 더 작은 값인 0.0005를 적용하였다.

항목	설정	항목	설정
Epoch	50	Augmentation	None
Batch size	32	Pretrained	True
Optimizer	Adam	Input size	224×224
Learning rate	CNN: 0.001 / Transformer: 0.0005	Seed	42
Scheduler	None	Dataset	raw-20260509-v1
Loss	CrossEntropyLoss	-	-

3-4. 모델 선정 기준

모든 비교 실험은 Validation Macro F1-score를 1차 선정 기준으로 사용하였다. Backbone 비교 실험에서 각 CNN 및 Transformer Backbone은 먼저 seed=42로 학습한 뒤, 계열별 상위 2개 모델에 대해 seed를 변경하여 2회 추가 학습을 수행하였다. 이후 총 3회 실험의 평균 Validation Macro F1-score를 계산하여 Best CNN Backbone과 Best Transformer Backbone을 선정하였다. 또한 최종 Backbone 선정 시에는 단순 성능뿐 아니라 다음 항목을 함께 고려하였다.

- Validation Loss 안정성
- 학습 시간

- Overfitting 여부 (Train/Validation 성능 차이)

이를 통해 높은 성능과 안정성을 동시에 만족하는 모델을 최종 Backbone으로 선정하였다.

3-5. Backbone 비교 결과

CNN 계열과 Transformer 계열 Backbone을 비교하였다. CNN 계열에서는 EfficientNet-B0가 평균 Validation Macro F1 약 0.7892를 기록하며 Best CNN Backbone으로 선정되었다. Transformer 계열에서는 Swin-T가 평균 Validation Macro F1 약 0.8850을 기록하며 가장 우수한 성능을 보였다. 또한 Swin-T는 Validation Loss가 가장 안정적이었고, 학습 시간과 Overfitting 측면에서도 우수한 결과를 보여 최종 Backbone으로 선정하였다.

항목	EfficientNet-B0	Swin-T
평균 Val Macro F1	약 0.7892	약 0.8850
Validation Loss	약 0.81	약 0.49
평균 학습 시간	약 30분 34초	약 27분 40초
Overfitting	존재	상대적으로 적음

3-6. 데이터셋 정제 후 재검증 결과

Best Backbone으로 선정된 Swin-T를 고정한 뒤, 데이터셋을 raw-20260509-v1에서 cls_raw-20260525-v2로 변경하여 재실험하였다.

재검증 결과, validation loss가 눈에 띄게 감소하였고, accuracy와 macro-F1도 크게 향상되었다. 모델 구조나 주요 설정을 변경하지 않고 데이터셋만 정제했음에도 성능이 개선되었다는 점에서, 이미지 분류 모델의 성능은 데이터 품질에 큰 영향을 받는다는 것을 확인할 수 있었다.

항목	정제 전	정제 후
Dataset	raw-20260509-v1	cls_raw-20260525-v2
Validation Macro F1	0.88008 (3-seed 평균)	0.92209
Validation Loss	0.49009 (3-seed 평균)	0.29486
Validation Accuracy	0.88060 (3-seed 평균)	0.91971

3-7. Augmentation 실험: None vs MixUp vs CutMix 결과

Augmentation 실험에서는 Swin-T와 정제된 데이터셋을 고정한 상태에서 **None**, **MixUp**, **CutMix**를 비교했다. MixUp 실험은 validation macro-F1 0.92200을 기록했지만 baseline 0.92209보다 근소하게 낮았고, CutMix는 0.92148로 baseline보다 낮았다. 따라서 최종 Best Augmentation은 None, 즉 augmentation 미적용으로 선정되었다.

실험	Best Validation Macro F1	결론
None	0.92209	가장 높음

실험	Best Validation Macro F1	결론
MixUp	0.92200	거의 동일하나 개선 없음
CutMix	0.92148	소폭 감소

3-8. Optimizer 및 Hyperparameter Tuning 결과

Optimizer tuning에서는 Learning Rate, Batch Size, Optimizer, Scheduler, Weight Decay, Label Smoothing에 대해 순차적으로 비교 실험을 수행하였다. 각 실험은 validation macro-F1을 기준으로 평가하였으며, 가장 우수한 성능을 보인 설정을 최종 모델에 적용하였다.

항목	비교값	최종 선택
Learning Rate	0.0005, 0.0001	0.0005
Batch Size	32, 16	32
Optimizer	Adam, AdamW	AdamW
Scheduler	None, CosineAnnealingLR	None
Weight Decay	0.01, 0.05	0.05
Label Smoothing	0.0, 0.05, 0.1	0.0 (사용 안 함)

Adam을 AdamW로 변경했을 때 validation macro-F1이 0.92148에서 0.92230으로 소폭 향상되었다. 이는 AdamW가 weight decay를 decoupling 방식으로 적용하기 때문에 Swin-T와 같은 Transformer 계열 모델에서 더 안정적인 regularization 효과를 낼 수 있다고 해석된다.

실험	Best Val Macro F1
Adam	0.92148
AdamW	0.92230

최종 선정 모델의 설정은 다음과 같다.

항목	최종 설정	항목	최종 설정
Backbone	Swin-T	Optimizer	AdamW
Dataset	cls_raw-20260525-v2	Scheduler	None
Augmentation	None	Weight Decay	0.05
Learning Rate	0.0005	Label Smoothing	0.0
Batch Size	32	Checkpoint	./outputs/classification/cls_swin-t_base_cls_raw-20260525-v2_lr-0005_bs-32_adamw_none_wdc-0.05_ls-0.0_best.pth

3-9. 최종 모델 성공 기준

최종 선정 모델은 Test Dataset 평가에서 다음 기준을 만족하는 것을 목표로 하였다.

- Test Accuracy ≥ 0.85
- Test Macro F1 ≥ 0.85
- Confusion Matrix에서 대각선 집중
- Latent Space UMAP에서 클래스별 Cluster 형성
- Grad-CAM 시각화 정상 생성

4. 이미지 캡셔닝 설계 및 실험 결과

4-1. 전체 실험 흐름

이미지 캡션 실험은 다음 순서로 진행되었다. Decoder Baseline 모델을 먼저 선정하고 데이터셋 확장 이후 Encoder backbone 비교 실험을 했다. 이후에는 차례대로 Tokenizer, Transformer Decoder 구조, 일반화 및 정규화 성능 향상, 최적화, Decoding 알고리즘 비교, Test Evaluation 으로 이어지는 흐름으로 정의했다.

Step 1. Decoder Baseline 선정
Step 2. 데이터셋 확장
Step 3. Encoder 비교
Step 4. Tokenizer 비교
Step 5. Transformer Decoder 구조 실험
Step 6. 정규화 및 일반화 성능 개선
Step 7. 최적화 실험
Step 8. Decoder Algorithm 비교
Final. Test Dataset Evaluation

4-2. 사용 모델 구조

캡션 실험에서는 Decoder와 Encoder를 분리하여 독립적으로 비교했다. Decoder는 RNN 계열과 Transformer 계열을 비교했다. Encoder는 사전 학습된 모델 기반으로 CNN 계열과 Transformer 계열에서 선정하여 backbone 성능을 비교했다.

Decoder 비교 모델

구분	모델	역할
RNN	LSTM	RNN 계열의 순차적 문장 생성 구조
RNN	GRU	LSTM보다 경량화된 RNN 구조

구분	모델	역할
Transformer	Transformer	Self-Attention 기반 문장 생성 구조

Encoder 비교 모델

구분	모델	역할
CNN	ResNet18	CNN 계열의 baseline 모델
Transformer	ViT-S/16	Self-Attention 기반 Vision Encoder
Transformer	Swin-T	Window Attention 기반 Vision Encoder

4-3. 기본 학습 조건

실험 간 공정한 비교를 위해 아래 조건을 고정하였다.

항목	설정	항목	설정
Epoch	20	Max Caption Length	30
Batch Size	32	Encoder	Pretrained
Optimizer	Adam	Encoder Input Size	Pretrained
Learning rate	0.0001	Seed	42
Scheduler	None	Dataset	raw-20260509-v1
Loss	CrossEntropyLoss	-	-

4-4. 모델 선정 기준

Decoder 모델의 성능 검증은 정성 평가를 최우선 기준으로 삼아 최종 모델을 판단하며, 정성적 판별이 모호한 경우에 한하여 정량 평가 지표를 보조적인 판정 도구로 활용한다.

평가 방식	지표 및 기준	목적
정성 평가	생성 문장의 자연스러움, 객체 설명 정확도, 반복 생성 및 hallucination 여부	캡션 문장의 문법적 완성도와 시각 정보 일치성을 심층적으로 평가
정량 평가	CIDEr, BLEU, Validation Loss	객관적인 수치 비교를 통해 모델의 기본적인 생성 성능 및 수렴도를 검증

4-5. Decoder Baseline 비교 결과

LSTM, GRU, Transformer 세 모델 모두 일부 이미지에서는 유사한 캡션을 생성하였으나, Transformer가 전체 데이터셋 기준 정량 평가에서 가장 우수한 성능을 보였다. 이는 Self-Attention 기반 구조가 이미지 특징과 문장 내 단어 간 관계를 효과적으로 학습할 수 있기 때문으로 해석하였다.

정성 지표



- **LSTM** : in this image we can see an airplane flying in the sky
- **GRU** : in this image we can see an airplane flying in the sky
- **Transformer** : in this image we can see an airplane flying in the sky

정량 지표

Decoder	Validation Loss	BLEU-4	CIDEr
LSTM	0.99302	0.37909	0.74282
GRU	0.96236	0.38102	0.67165
Transformer	0.84491	0.40138	0.79299

4-6. 데이터셋 변경 결과

항목	raw-20260509-v1	cap_raw-20260524-v1
데이터 특성	객체 분류 중심	장면 설명 중심
이미지당 캡션 수	2	5
학습 시 사용 캡션 수	1	2
학습 목표	객체 인식	객체, 상태, 관계, 배경 설명

데이터셋 변경 이후 정량적 평가 지표는 기존 대비 감소하였으나, 이는 데이터셋의 난이도 증가에 따른 결과로 해석하였다. 기존 데이터셋에서는 반복 생성되는 문장이 있으며, 주로 단일 객체를 설명하는 수준에 머물렀다. 반면 COCO Dataset 적용 이후에는 객체 간 관계와 위치 정보를 포함하는 다양한 문장 구조가 생성되었다.

정성 지표

```
# raw-20260509-v1
in this image we can see an airplane flying in the sky,
in this image we can see a food item on the plate which is placed on the table,
in this image we can see a flower in the background there are plants

# cap_raw-20260524-v1
a desk with a computer and a keyboard and mouse .
```

a person with a teddy bear sitting on a bed .
a cat is sitting in the middle of a chair .


정량 지표

데이터셋	Validation Loss	BLEU-4	CIDEr
raw-20260509-v1	0.84491	0.40138	0.79299
cap_raw-20260524-v1	2.59930	0.14241	0.43862

4-7. Encoder 비교 결과

Swin-T가 정량 평가와 정성 평가 모두에서 가장 우수한 성능을 보였다. ResNet18은 동일 객체를 반복 생성하였으며, ViT는 unk 토큰이 생성되었다. Swin-T는 Window Attention과 계층적 구조를 통해 지역 정보와 전역 정보를 균형 있게 학습할 수 있어 현재 데이터셋 환경에서 가장 우수한 성능을 보인 것으로 판단된다.

정성 지표



- **ResNet18** : a blue and blue boat filled with lots of boats .
- **Swin-T** : A group of boats with colorful flags at docked
- **ViT** : a group of boats with <unk> on a body of water

정량 지표

Encoder	Validation Loss	BLEU-4	CIDEr
ResNet18	2.59930	0.14241	0.43862
Swin-T	2.44602	0.17090	0.55499
ViT	2.50297	0.16090	0.52026

4-8. Tokenizer 비교 결과

Word-level에서 Subword-level로 변경한 결과, BLEU 및 CIDEr 성능이 전반적으로 향상되었다. 하지만 실제 생성된 문장을 확인한 결과, Hallucination 현상과 의미적으로 부자연스러운 문장이 생성되었다. 이는 모델이 이미지 자체를 보고 문장을 만들기보다, 학습용 캡션에 자주 나오는 언어 패턴을 흉내만 낸 것으로 분석하였다. 본 프로젝트에서는 정성 평가를 우선시하므로 객체 인식 정확도와 문장 자연스러움이 더 우수했던 Word-level Tokenizer를 최종 설정으로 선정하였다.

정성 지표



- **Subword 1000** : a couple of men standing next to each other.
- **Subword 1500** : a couple of people are sitting on a bench.
- **Subword 2000** : a couple of people with a beardy seat in a room.

정량 지표

Tokenizer	Validation Loss	BLEU-4	CIDEr
Word-level	2.44602	0.17090	0.55499
Subword vocab 1000	2.28855	0.19310	0.63337
Subword vocab 1500	2.39733	0.19366	0.63158
Subword vocab 2000	2.44271	0.19884	0.63536

4-9. Transformer Decoder 구조 실험

Transformer Decoder 구조 실험은 layer 수, Hidden Dimension, Attention Head 개수, positional encoding, activation function을 개별적으로 확인했다. 다만 각 항목의 성능 차이가 크지 않았기 때문에, 유의미한 영향을 미친 핵심 결과를 중심으로 기술했다.

4.9.1. Attention Head 개수 최적화(nhead=4 vs nhead=8)

정량 평가 기준에서 유사한 성능을 기록하였으나, 캡션 품질에서 nhead=4는 Hallucination 현상이 확인되었다. 실제 캡션 문장의 정확성과 출력 신뢰도가 더 우수한 **nhead=8** 구조를 최종 선택하였다.

4.9.2. Positional Encoding 방식 검증 (Learnable vs Sinusoidal)

Learnable을 적용했을 때, BLEU 및 CIDEr 성능 향상에 기여하였으나, Validation Loss가 증가하였고 실제 캡션 품질에서는 Hallucination이 증가하는 문제가 확인되었다. 반면,

Sinusoidal은 일반화 성능이 더 안정적으로 유지되고 있다고 판단하였다.

정성 지표



- **nhead4** : a pizza with a knife and a fork on a plate .
- **nhead8** : a plate of pizza with cheese and vegetables on a table .



- **sinusoidal** : a woman is petting a giraffe in a zoo .
- **learnable** : a woman is sitting on a dirt road with a giraffe behind her .

정량 지표

항목	설정 값	Validation Loss	BLEU-4	CIDEr
Attention Head	4	2.44456	0.18010	0.56305
Attention Head	8	2.44293	0.17690	0.56046
Positional Encoding	sinusoidal	2.44293	0.17690	0.56046
Positional Encoding	learnable	2.47940	0.18118	0.56984

종합 결과 지표

항목	실험 값	주요 결과	최종 선정
n_layers	2, 4, 6	Layer 수 증가에 따라 BLEU 및 CIDEr 향상	6
d_model	256, 512, 768	512가 가장 우수한 Validation Loss 및 CIDEr 기록	512
nhead	4, 8	nhead=4는 Hallucination 발생, nhead=8이 더 자연스러운 캡션 생성	8

항목	실험 값	주요 결과	최종 선정
Activation	ReLU, GELU	ReLU와 GELU 캡션 품질 유사, ReLU가 BLEU-4 및 CIDEr 우세	ReLU
Positional Encoding	Sinusoidal, Learnable	Learnable은 Hallucination 발생, Sinusoidal이 더 안정적	Sinusoidal

4-10. 정규화 및 일반화 성능 개선 결과

4-10-1. Dropout

Dropout 비율이 증가할수록 Train Loss는 증가했지만, BLEU와 CIDEr 성능은 전반적으로 향상되었다. Validation Loss는 Dropout 0.2에서 가장 낮았으나, 실제 생성 캡션 품질은 세 설정 간 큰 차이가 없었기 때문에 정량 지표와 일반화 성능을 더 중요한 판단 기준으로 보았다. 따라서 본 실험에서는 가장 높은 BLEU 및 CIDEr 성능을 기록하고 과적합 완화 효과를 기대할 수 있는 Dropout 0.3 을 최종 설정으로 선정하였다.

정성 지표



- **0.1** : a person on a snowboard on a snowy slope .
- **0.2** : a person on a snow board on a snowy hill .
- **0.3** : a person on a snowboard on a snowy slope .

정량 지표

Dropout	Validation Loss	BLEU-4	CIDEr
0.1	2.44293	0.17690	0.56046
0.2	2.41895	0.17729	0.56765
0.3	2.42717	0.18564	0.57074

4-10-2. Weight Decay

Weight Decay 값을 변경해도 정량적 성능은 전반적으로 유사했다. 반면 생성 캡션 비교 결과, Weight Decay 0.0005에서는 Hallucination과 반복 생성 현상이 확인되었다. 따라서 정량 지

표보다 실제 캡션 안정성을 함께 고려하여, 가장 낮은 Validation Loss와 안정적인 생성 품질을 보인 Weight Decay 0.001을 최종 설정으로 선정하였다.

정성 지표



- **0.0001** : a giraffe standing next to a woman in a zoo .
- **0.0005** : a woman standing next to a giraffe eating a hot dog .
- **0.001** : a giraffe standing next to a woman in a zoo .

정량 지표

Weight Decay	Validation Loss	BLEU-4	CIDEr
0.0001	2.42717	0.18564	0.57074
0.0005	2.42821	0.18521	0.57357
0.001	2.42643	0.18429	0.57031

4-10-3. Label Smoothing

Label Smoothing을 적용한 결과, BLEU 및 CIDEr는 소폭 향상되었으며 Label Smoothing 0.05에서 가장 높은 성능을 기록하였다. 그러나 Validation Loss는 Label Smoothing 값이 증가할수록 지속적으로 증가하였으며, 0.05와 0.1에서는 객체를 잘못 인식하는 현상이 관찰되었다. 이에 따라 가장 안정적인 캡션을 생성한 Label Smoothing 0을 최종 설정으로 선정하였다.

정성 지표



- **0** : a pizza on a plate on a table .
- **0.05** : a pizza with cheese and cheese on a plate .
- **0.1** : a plate of pizza with cheese and cheese .

정량 지표

Label Smoothing	Validation Loss	BLEU-4	CIDEr
0	2.42643	0.18429	0.57031
0.05	2.90918	0.18723	0.57567
0.1	3.33286	0.18638	0.57487

4-11. 최적화 실험 결과

4-11-1. Learning Rate Tuning

0.0001이 Validation Loss, BLEU-4, CIDEr 모두에서 가장 우수한 성능을 기록하였다. 0.0003으로 증가시킨 경우와 0.00005로 감소시킨 경우 Validation Loss와 BLEU, CIDEr 모두 악화되었고, Hallucination 현상도 확인되었다. 이는 0.0001에 비해 일반화 성능이 떨어지는 최적점에 도달한 것으로 판단된다

정성 지표



- **0.0001** : a giraffe standing next to a woman in a zoo .
- **0.0003** : a woman standing next to a giraffe in a zoo .
- **0.00005** : a woman standing next to a giraffe eating a fence .

정량 지표

Learning Rate	Validation Loss	BLEU-4	CIDEr
0.0001	2.42643	0.18429	0.57031
0.0003	2.51517	0.17115	0.54980
0.00005	2.51623	0.17589	0.53540

4-11-2. Learning Rate Scheduler

Noam Scheduler를 적용한 결과, Validation Loss, BLEU-4, CIDEr 모두 감소하였으며, 전반적인 성능 저하가 확인되었다. 생성 캡션 비교 결과에서도 Scheduler 적용 모델은 Hallucination 현상이 관찰되었다.

반면 Scheduler를 사용하지 않은 모델은 이미지의 주요 객체와 상황을 보다 자연스럽게 안정적으로 설명하였다.

정성 지표



- **None** : a giraffe standing next to a woman in a zoo .
- **Scheduler** : a woman standing next to a giraffe eating a fence .

정량 지표

Scheduler	Validation Loss	BLEU-4	CIDEr
None	2.42643	0.18429	0.57031
Noam Scheduler	2.51623	0.17589	0.53540

4-11-3. Batch Size

Batch Size 32에서 가장 우수한 Validation Loss, BLEU-4, CIDEr 성능을 기록하였다. Batch Size 16은 가장 낮은 Train Loss를 기록하였으나, Validation 성능에서는 Batch Size 32보다 우수하지 않았고 생성 캡션에서도 일부 부자연스러운 문장을 생성하였다. Batch Size 64는 모든 평가에 대해 악화되었으며, 생성 캡션에서도 반복 생성 현상이 확인되었다.

정성 지표



- **16** : a woman is petting a giraffe and a woman .
- **32** : a giraffe standing next to a woman in a zoo .
- **64** : a woman standing next to a giraffe and a woman .



- **16** : a pizza with toppings on a plate on a table .
- **32** : a pizza on a plate on a table .
- **64** : a plate of food with a fork and a fork .

정량 지표

Batch Size	Validation Loss	BLEU-4	CIDEr
16	2.4285	0.17945	0.56824
32	2.42643	0.18429	0.57031
64	2.45775	0.17186	0.53895

4-12. Decoding Algorithm 비교 결과

Beam Search를 적용한 결과, 모델 구조나 학습 과정의 변경 없이도 BLEU 및 CIDEr 성능이 크게 향상되었다. 생성 캡션 비교 결과에서도 Beam Search는 객체를 보다 구체적이고 풍부한 표현으로 설명하는 경향을 보였다.

Beam Size 3과 Beam Size 5는 성능 차이가 매우 작았으며, 실제 생성 캡션 또한 거의 동일한 수준을 보였다. 따라서 성능과 추론 속도를 종합적으로 고려하여 최종 Decoding 방식은 Beam Search(Beam Size=3)으로 선정하였다.

정성 지표



- **greedy** : a pizza on a plate on a table .
- **beam3** : a slice of pizza on a plate on a table .
- **beam5** : a slice of pizza on a plate on a table .



- **greedy** : a person on a snowboard on a snowy slope .
- **beam3** : a man riding skis down a snow covered slope .
- **beam5** : a man riding skis down a snow covered slope .

정량 지표

Decoding Algorithm	Validation Loss	BLEU-4	CIDEr
Greedy	2.42643	0.18429	0.57031
Beam Search 3	2.42643	0.19973	0.60544
Beam Search 5	2.42643	0.20061	0.60638

최종 이미지 캡셔닝 모델은 다음과 같이 정리했다.

항목	최종 설정	항목	최종 설정
Dataset	cap_raw-20260524-v1	Dropout	0.3
Encoder	Swin-T	Weight Decay	0.001
Decoder	Transformer Decoder	Label Smoothing	0
Tokenizer	Word-level	Optimizer	AdamW
n_layers	6	Learning Rate	0.0001
d_model	512	Scheduler	None
nhead	8	Batch Size	32
Activation	ReLU	Decoding	Beam Search 3
Positional Encoding	Sinusoidal	Checkpoint	./outputs/captioning/swin-transformer_final_best.pt

4-11. 최종 모델 성공 기준

최종 선정 모델은 Test Dataset 평가에서 다음 기준을 만족하는 것을 목표로 하였다.

1. 정성 평가 기준

- 이미지의 주요 객체를 정확하게 설명할 것
- 객체 간 관계 및 상황 정보를 자연스럽게 표현할 것
- 반복 생성(Repetition)이 발생하지 않을 것

- 이미지에 존재하지 않는 객체 또는 상황을 생성하는 Hallucination이 최소화될 것

2. 정량 평가 기준

Metirc score $\geq$ 보통

Metric	낮음	보통	괜찮음	좋음
BLEU-1	< 0.40	0.40 ~ 0.60	0.60 ~ 0.75	> 0.75
BLEU-2	< 0.25	0.25 ~ 0.45	0.45 ~ 0.60	> 0.60
BLEU-3	< 0.15	0.15 ~ 0.30	0.30 ~ 0.45	> 0.45
BLEU-4	< 0.10	0.10 ~ 0.20	0.20 ~ 0.35	> 0.35
CIDEr	< 0.30	0.30 ~ 0.60	0.60 ~ 1.00	> 1.00

3. Attention Heatmap 시각화 정상

5. 결과 분석 및 평가

5-1. 최종 이미지 분류 모델 성능

최종 이미지 분류 모델은 Swin-T Backbone, 정제 데이터셋 `cls_raw-20260525-v2`, AdamW optimizer, weight decay 0.05 조합으로 선정되었다.

Test dataset 평가 결과는 다음과 같았다.

Metric	Score
Accuracy	0.8964
Precision	0.9001
Recall	0.8961
Macro F1	0.8961

최종 모델은 test accuracy와 macro-F1 모두 약 0.896을 기록하며, 사전에 설정한 목표 기준인 0.85 이상을 충족했다. 또한 Accuracy와 Macro-F1이 유사하게 나타나 전체 클래스에 대해 비교적 균형 잡힌 성능을 보였다.

5-2. 데이터셋 정제 전후 변화

분류 모델 성능에서 가장 의미 있었던 변화는 데이터셋 정제 전후의 성능 차이였다.

항목	정제 전	정제 후
Validation Loss	0.49009	0.29486
Validation Accuracy	0.88060	0.91971
Validation Macro F1	0.88008	0.92209

데이터셋 정제 후 validation loss는 크게 감소했고, validation macro-F1은 약 0.88에서 약 0.92로 상승했다. 모델 구조 변화 없이도 성능이 향상되어, 성능 저하 원인이 모델 자체에만 있지 않음을 확인할 수 있었다. 이는 데이터 품질이 모델 성능에 직접 영향을 미침을 보여준다. 따라서 데이터셋 정제는 최종 성능 향상에 기여한 핵심 요인 중 하나였다.


5-3. Confusion Matrix 분석

Confusion Matrix에서는 대부분의 샘플이 대각선에 집중되어 전체적으로 높은 분류 성능을 보였다. 특히 airplane, banana, bicycle, bulldog, elephant, motorcycle, sunflower 등은 거의 완벽하게 분류되었다. 반면 bracelet, necklace, earrings, sandwich, salad, dumpling 등은 상대적으로 오분류가 많이 발생했다.

성능이 낮은 원인은 다음과 같이 해석될 수 있다. 액세서리 클래스(earrings, bracelet, necklace)는 객체가 작고 배경 영향이 커 상대적으로 낮은 성능을 보였으며, 클래스 간 시각적 유사성으로 오분류가 발생했다. 음식 클래스(sandwich, salad, dumpling)는 내부 다양성이 크고 시각적 특징이 유사해 혼동이 발생했다.

또한 저해상도 이미지가 많이 포함된 클래스에 대한 추가 분석 결과, 오분류는 해상도보다 시각적으로 유사한 클래스 간 혼동에서 주로 발생하였다.

구분	클래스	해석
성능 우수	banana, bicycle, bulldog, elephant, motorcycle, sunflower	객체 형태와 특징이 뚜렷함
성능 낮음	earrings, bracelet, necklace	객체가 작고 배경 영향이 큼
성능 낮음	sandwich, salad, dumpling	음식류는 형태 변화가 크고 클래스 간 유사성이 높음



5-4. 저해상도 이미지 영향 분석

초기 데이터 수집 시 최소 해상도 기준을 256px로 설정했으나, 데이터 확보를 위해 이후 128px로 완화하였다. 이에 따라 일부 클래스에는 256px 미만 이미지가 상대적으로 많이 포함되었다. 특히 일부 클래스는 전체 데이터의 약 40~55%가 256px 미만 이미지로 구성되었다.


클래스	256px 미만 이미지 수	비율
aster	119	54%
lavender	119	54%
squirrel	103장	47%
marigold	99장	45%
iris	100장	45%
butterfly	79장	36%
penguin	79장	36%
horse	74장	34%

해당 클래스들을 대상으로 Confusion Matrix를 추가 분석한 결과, 오분류는 저해상도 이미지 자체보다는 시각적으로 유사한 클래스 간 혼동에서 주로 발생하였다. 꽃류(aster, lavender, marigold, iris)는 유사한 꽃 클래스와, squirrel은 일부 동물 클래스와 혼동되는 패턴이 확인되었다. 반면 저해상도 이미지 비율 자체와 분류 성능 사이에는 뚜렷한 상관관계가 나타나지 않았다.

이는 현재 데이터셋에서는 이미지 해상도보다 객체의 형태적 유사성이 오분류에 더 큰 영향을 미쳤음을 시사한다. 따라서 향후 성능 개선을 위해서는 해상도 향상보다 유사 클래스 데이터 다양성 확보와 샘플 재검수가 더욱 효과적일 것으로 판단된다.


5-5. Latent Space UMAP 분석

UMAP 시각화 결과, airplane, bicycle, elephant, motorcycle, sunflower 등은 feature space에서 비교적 뚜렷한 cluster를 형성했다. 따라서 모델이 해당 클래스의 시각적 특징을 잘 분리해서 학습했음을 시사한다. 반대로 꽃류와 음식류 일부는 cluster가 서로 겹치거나 가까운 위치에 분포했다. 이는 모델이 해당 클래스들을 완전히 분리하지 못했다는 의미이기도 하지만, 동시에 실제 이미지 특성상 시각적 유사성이 높다는 점을 반영한다.



5-6. Grad-CAM 분석

Grad-CAM 분석에서 정분류 사례는 activation이 객체 중심부에 집중되는 경향을 보였다. 예를 들어 banana나 명확한 객체 이미지에서는 모델이 배경보다 실제 객체 영역을 중심으로 판단했다. 이는 모델이 의미 있는 시각적 특징을 활용했음을 보여준 반면 오분류 사례에서는 activation이 객체 외부, 배경, 주변 물체로 분산되는 경우가 있었다. 특히 작은 객체나 복잡한 배경에서는 주변 정보에 더 의존하는 경향이 나타났다.



정분류 사례: banana




오분류 사례: aster

5-7. 학습 곡선 해석 및 성능 한계

다만 최종 모델도 다음과 같은 한계가 존재한다.

- 액세서리류는 객체가 작고 배경 비중이 커서 분류 난이도가 높다.
- 음식류는 같은 클래스 안에서도 모양이 다양하고, 서로 다른 음식 간 시각적 유사성이 높다.

- validation/test split에서 클래스당 샘플 수가 많지 않기 때문에 일부 클래스는 몇 장의 오분류만으로도 F1이 크게 흔들릴 수 있다.
- MixUp과 CutMix는 이번 정제 데이터셋에서는 성능 개선으로 이어지지 않았다.



5-8. 최종 이미지 캡셔닝 모델 성능



정량 평가

Metric	Score
Bleu_1	0.58290
Bleu_2	0.41275
Bleu_3	0.28504
Bleu_4	0.19973
CIDEr	0.60544


최종 모델의 정량 평가 결과는 Bleu는 “보통”, CIDEr은 “괜찮음” 범위에 속했다. 이는 사전에 설정한 목표 기준인 “보통” 이상을 충족하는 결과였다

정성 평가

a man riding a horse on a dirt road .

생성된 캡션은 이미지의 주요 객체와 상황을 정확하게 설명하였으며, Hallucination 및 반복 생성 없이 자연스러운 문장을 생성하여 정성 평가 기준에 부합하였다.

Attention Heatmap 시각화



생성 과정에서 각 단어가 의미하는 객체 또는 영역에 Attention이 집중되는 것이 확인되었으며, 모델이 시각적 정보를 기반으로 캡션을 생성하고 있음을 확인할 수 있었다. 예를 들면 “horse”가 생성되는 시점에 말이 위치한 영역에 Attention이 집중되었다.

6. MLOps 및 배포

본 프로젝트에서는 실험 재현성과 협업 효율을 높이기 위해 GitHub, Docker, DVC, W&B, Gradio, Hugging Face Spaces를 사용했다.

도구	사용 목적
GitHub	코드 버전 관리 및 협업
Docker	팀원 간 동일한 실행 환경 구성
DVC	데이터셋과 모델 checkpoint 버전 관리
W&B	실험 설정, metric, 그래프 기록

도구	사용 목적
Gradio	모델 결과를 웹 데모 형태로 제공
Hugging Face Spaces	Gradio 데모 배포

7. 결론 및 회고

7-1. 데이터 품질의 중요성

- 깨진 이미지, 중복 이미지, 라벨 오류 가능 이미지를 정제한 뒤 모델 성능이 눈에 띄게 향상되었다.
- 이미지 분류는 객체 중심의 데이터가 중요하지만, 이미지 캡셔닝은 장면 중심의 데이터가 필요하다.
- 낮은 성능이 항상 모델의 한계만을 의미하는 것은 아니며, 데이터 구성과 품질을 함께 확인해야 정확하게 해석할 수 있다.

7-2. 정량 평가와 정성 평가의 필요성

1. 실제 생성 품질을 판단하기 위해선 정성 평가가 필요하다
2. 정량 평가는 여러 실험 결과를 같은 기준에서 비교할 수 있게 해준다.
3. 최종 모델 선정에는 두 평가를 함께 고려해야 한다

7-3. 향후 개선 방향

개선 방향	내용
낮은 성능 클래스 보강	earrings, bracelet, necklace, sandwich, salad, dumpling 중심으로 데이터 재검수
캡셔닝 데이터셋 확대	현재 학습 데이터는 약 7,700장 규모로 성능이 제한적임, 더 큰 규모의 데이터셋을 활용하여 일반화 성능 향상
오분류 샘플 분석 강화	Confusion Matrix와 Grad-CAM을 함께 활용해 원인 분석
캡셔닝 평가 지표 확장	BLEU, CIDEr 외 METEOR, ROUGE-L, SPICE 검토
Gradio 통합 서비스 개선	분류 결과와 캡션 결과를 한 화면에서 비교 가능하도록 UI 개선
모델 경량화 검토	배포 속도와 사용성을 고려한 최적화

7-4. 최종 회고

본 프로젝트를 통해 이미지 분류와 이미지 캡셔닝을 모두 수행하며 데이터 품질, 모델 구조, 평가 방법이 모델 성능에 중요한 영향을 준다는 점을 확인하였다.

이미지 캡셔닝에서는 정량 지표만으로 생성 문장의 품질을 판단하기 어렵기 때문에, 실제 문장의 자연스러움과 이미지와의 일치 여부를 함께 평가해야 한다.